

Métodos de Computação Experimental e Quantitativa

Aula 02: **Métricas e Validade Experimental**

Prof. Dr. Leonardo N. Ferreira e Prof. Dr. Wemerson D. Parreira

Conteúdo

1. Métricas na Computação Experimental
2. Validação $\times$ Verificação
3. Ameaças à Validade (Conclusão, Interna, Construto e Externa)
4. Aplicação Prática (Estudo de Caso)

Objetivos da Aula

1. **Definir** métricas objetivas e reprodutíveis.
2. **Distinguir** validação de verificação.
3. **Classificar** ameaças à validade de experimentos.

Objetivos da Aula

1. **Definir** métricas objetivas e reprodutíveis.

2. **Distinguir** validação de verificação.

3. **Classificar** ameaças à validade de experimentos.

Objetivos da Aula

1. **Definir** métricas objetivas e reprodutíveis.

2. **Distinguir** validação de verificação.

3. **Classificar** ameaças à validade de experimentos.

MÉTRICAS, VALIDAÇÃO / VERIFICAÇÃO E AMEAÇAS À VALIDADE

Visão Geral

Métricas

O que exatamente eu meço?

Validação × Verificação

Meço a coisa certa, do jeito certo?

Ameaças à validade

O que pode enganar a conclusão?

Métricas

Conceitos Fundamentais

1. Atributo

A característica conceitual ou qualitativa que queremos avaliar.

Exemplos:

- Qualidade de código
- Usabilidade
- Desempenho

2. Métrica

O procedimento ou fórmula para quantificar o atributo.

Exemplos:

- Bugs por KLOC
- Tempo de tarefa (s)
- Tempo de resposta (ms)

3. Dado Bruto

Os valores numéricos diretos coletados na medição.

Exemplos:

- 15 bugs
- 120 segundos
- 250 ms

A métrica deve possuir:

- **Objetividade**: independe de quem realiza a medição;
- **Reprodutibilidade**: gera o mesmo resultado sob as mesmas condições;
- **Sensibilidade**: é capaz de detectar variações reais no atributo.

Exercício 1 Métricas

Enunciado

Para cada atributo abaixo, proponha **uma métrica objetiva e reprodutível** e justifique em uma frase:

a) manutenibilidade de código;

b) usabilidade de uma interface;

c) escalabilidade de um sistema;

d) confiabilidade de um serviço.

Cheque rápido

Sua métrica é **objetiva e reprodutível**, ou depende de opinião? Ela é uma métrica, ou apenas um dado bruto?

Exercício 1 Possíveis respostas

Atributo	Métrica proposta (exemplo)
Manutenibilidade	Complexidade ciclomática média / índice de acoplamento
Usabilidade	Tempo médio de tarefa-padrão / taxa de erro do usuário
Escalabilidade	Tempo de resposta $\times$ nº de usuários simultâneos
Confiabilidade	Tempo médio entre falhas (MTBF) / taxa de disponibilidade

Ponto de atenção

Cuidado com confundir **métrica** com **dado bruto** (ex.: “número de reclamações” sem normalizar) e com métricas subjetivas (“parece rápido”).

Validar × verificar

	Verificação	Validação
Pergunta central	Estou medindo **corretamente**?	Estou medindo a coisa **certa**?
Foco	Consistência interna, correção do procedimento	Correspondência com a realidade/objetivo pretendido
Exemplo	Conferir se os dados foram coletados conforme o protocolo	Conferir se a métrica escolhida realmente representa o conceito estudado

Analogia

- **Verificação** é construir o produto corretamente;
- **Validação** é construir o produto certo.

Exercício 2 Validação × Verificação

Enunciado

Classifique cada situação como problema de **verificação** ou de **validação**, justificando em uma frase:

a) O formulário de coleta de dados tinha um erro de digitação que trocou duas colunas;

b) A métrica escolhida foi “número de commits”, mas o objetivo era medir “qualidade do código”;

c) O script de análise estatística continha um erro de fórmula;

d) Mediu-se “tempo de resposta do servidor”, mas o problema de pesquisa era sobre “percepção de lentidão pelo usuário”.

Exercício 2 Respostas

a) **Verificação** – erro no procedimento de coleta;

b) **Validação** – métrica não representa o atributo de interesse;

c) **Verificação** – erro procedimental na análise;

d) **Validação** – descompasso entre o que foi medido e o conceito teórico de interesse (validade de construto).

Ponto de atenção

Muitos “erros metodológicos” apontados em artigos são, na verdade, problemas de **validação**, não de verificação – e isso tem implicações diferentes para a força da conclusão.

AMEAÇAS À VALIDADE

Variáveis Experimentais Definições

1. Variável Independente (VI)

Fator manipulado pelo pesquisador (**a causa**).

Exemplo: Estratégia de desenvolvimento (Pares vs. Individual).

2. Variável Dependente (VD)

Característica medida para avaliar o impacto da VI (**o efeito**).

Exemplo: Número de bugs ou tempo de desenvolvimento.

Variáveis Experimentais Definições

1. Variável Independente (VI)

Fator manipulado pelo pesquisador (**a causa**).

Exemplo: Estratégia de desenvolvimento (Pares vs. Individual).

2. Variável Dependente (VD)

Característica medida para avaliar o impacto da VI (**o efeito**).

Exemplo: Número de bugs ou tempo de desenvolvimento.

Variáveis Experimentais Definições

3. Variável de Controle

Fatores mantidos **constantes** para evitar interferências no resultado.

Exemplo: Complexidade da tarefa ou linguagem de programação.

4. Variável Moderadora

Variável que **altera** a força ou a direção da relação entre a VI e a VD.

Exemplo: Nível de experiência (a programação em pares pode beneficiar juniores, mas ter pouco efeito para seniores).

Variáveis Experimentais Definições

3. Variável de Controle

Fatores mantidos **constantes** para evitar interferências no resultado.

Exemplo: Complexidade da tarefa ou linguagem de programação.

4. Variável Moderadora

Variável que **altera** a força ou a direção da relação entre a VI e a VD.

Exemplo: Nível de experiência (a programação em pares pode beneficiar juniores, mas ter pouco efeito para seniores).

O que pode enganar a sua conclusão?

1. Validade de Conclusão

Existência de relação estatística entre VI e VD.

Questão: A relação entre variáveis é estatisticamente sustentável? (amostra pequena, testes inadequados)
Exemplo: Concluir que a ferramenta A é melhor após testá-la com apenas 3 desenvolvedores.

2. Validade de Construto

A métrica realmente mede o que se propõe a medir.

Questão: A métrica usada representa o conceito teórico de interesse?
Exemplo: Utilizar "linhas de código escritas"para medir a "produtividade"de um programador.

O que pode enganar a sua conclusão?

1. Validade de Conclusão

Existência de relação estatística entre VI e VD.

Questão: A relação entre variáveis é estatisticamente sustentável? (amostra pequena, testes inadequados)
Exemplo: Concluir que a ferramenta A é melhor após testá-la com apenas 3 desenvolvedores.

2. Validade de Construto

A métrica realmente mede o que se propõe a medir.

Questão: A métrica usada representa o conceito teórico de interesse?
Exemplo: Utilizar "linhas de código escritas"para medir a "produtividade"de um programador.

O que pode enganar a sua conclusão?

3. Validade Interna

Relação de causa e efeito direta.

Questão: O efeito foi mesmo causado pela VI ou por uma variável de confusão?
Exemplo: Comparar ferramentas usando seniores no grupo A e juniores no grupo B.

4. Validade Externa

Capacidade de generalização.

Questão: O resultado se aplica a outros contextos, equipes ou tecnologias?
Exemplo: Assumir que o resultado com alunos em tarefas de 1h vale na indústria.

O que pode enganar a sua conclusão?

3. Validade Interna

Relação de causa e efeito direta.

Questão: O efeito foi mesmo causado pela VI ou por uma variável de confusão?
Exemplo: Comparar ferramentas usando seniores no grupo A e juniores no grupo B.

4. Validade Externa

Capacidade de generalização.

Questão: O resultado se aplica a outros contextos, equipes ou tecnologias?
Exemplo: Assumir que o resultado com alunos em tarefas de 1h vale na indústria.

Exercício 3 Ameaças à validade

Enunciado

Para cada situação, identifique a ameaça predominante (conclusão, interna, construto ou externa) e proponha uma melhoria:

a) Estudo com apenas 4 participantes conclui que a Linguagem A é "significativamente" mais produtiva que a B;

b) Dois times comparados, mas um tinha desenvolvedores muito mais experientes;

c) Usa-se "linhas de código por hora" como métrica de "produtividade";

d) Apenas alunos, uma tarefa acadêmica simples, e conclui-se algo sobre "ambientes profissionais".

Correção Exercício 3

a) **Validade de conclusão** – amostra pequena para significância → aumentar amostra / teste apropriado;

b) **Validade interna** – experiência é variável de confusão → controlar/balancear experiência;

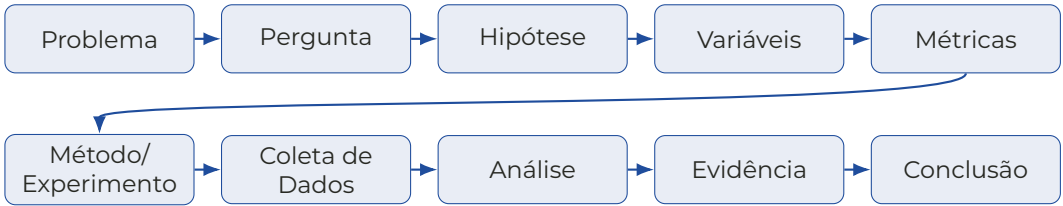
c) **Validade de construto** – linhas de código não captura “produtividade” → combinar com métricas de qualidade;

d) **Validade externa** – amostra/tarefa não representam contexto profissional → replicar com profissionais e tarefas reais.

DELINEAMENTO EXPERIMENTAL NA PRÁTICA

Verificação, validação e Ameaças na prática

O ciclo de investigação científica:



Onde os conceitos se encaixam:

- **Verificação**: Método/Experimento, Coleta de Dados e Análise;
- **Validação**: Variáveis e Métricas;
- **Ameaças à validade**: cruzam todo o fluxo, impactando a Conclusão.

Estudo de Caso Programação em Pares

Cenário

Uma equipe de desenvolvimento afirma que adotar **Programação em Pares** (*pair programming*) melhora o desempenho da equipe e a qualidade do software entregue, em comparação ao desenvolvimento individual.

Pergunta:

Essa afirmação, do jeito que está, é testável cientificamente? O que falta nela?

Estudo de Caso Reformulação

Problema

Falta de dados sistemáticos sobre o impacto da programação em pares nesta equipe.

Pergunta de investigação

A programação em pares melhora o desempenho e a qualidade em relação ao desenvolvimento individual?

Hipótese

A programação em pares reduz a quantidade de defeitos mantendo o tempo de entrega comparável.

Estudo de Caso Variáveis

- **Variável independente**: estratégia de desenvolvimento (pares vs. individual);
- **Variáveis dependentes**: qualidade (densidade de defeitos/KLOC) e desempenho (tempo de conclusão);
- **Variáveis de controle**: complexidade da tarefa, linguagem de programação;
- **Variável moderadora**: nível de experiência dos desenvolvedores (juniores vs. seniores);

Estudo de Caso Delineamento

- **Procedimento**: duplas e desenvolvedores individuais resolvem a mesma tarefa, sob as mesmas condições, com atribuição aleatória;
- **Critério de comparação**: média de defeitos e tempo entre grupos, com teste estatístico apropriado;
- **Ameaças à validade**:
  - **Interna**: experiência dos participantes;
  - **Externa**: uma única tarefa/domínio;
  - **Construto**: defeitos/KLOC representa bem “qualidade”?;
- **Conclusão possível**: os dados podem sustentar, refutar ou apenas sugerir uma tendência – nunca “provar” definitivamente.

Exercício

Enunciado

Retomando o estudo de caso da Programação em Pares, mas agora a equipe quer testar se o efeito da programação em pares muda conforme o nível de experiência dos desenvolvedores (juniores vs. seniores).

Estruture uma investigação completa contendo: problema; pergunta; hipótese; VI; VDs; variáveis de controle; variável moderadora; métricas; procedimento; critério de comparação; ao menos uma ameaça à validade; e o que os resultados poderiam (ou não) sustentar.

Respostas

Problema/Pergunta: O efeito da programação em pares varia conforme a experiência?

Hipótese: O benefício é maior para juniores do que para seniores.

Variáveis: VI (estratégia); VD (qualidade/tempo); Controle (tarefa/linguagem); Moderadora (experiência).

Procedimento: Grupos cruzados (júnior/sênior $\times$ par/individual) com atribuição aleatória.

Ameaça: Construto (critério para definir objetivamente “júnior” e “sênior”).

Conclusão: Resultados mostram tendências contextuais, não leis universais.

EXERCÍCIOS COMPLEMENTARES

Exercícios Complementares

Exercício 1

Qual a diferença entre método científico e técnica de pesquisa?

Resposta:
– **Método científico**: procedimentos lógicos gerais para produzir e validar conhecimento.
– **Técnica de pesquisa**: procedimento operacional específico (instrumentos, formulários).

Exercício 2

Em “sistemas que usam cache reduzem o tempo médio de resposta”, identifique VI e VD.

Resposta:
– **Variável independente**: uso de cache.
– **Variável dependente**: tempo médio de resposta.

Exercícios Complementares

Exercício 1

Qual a diferença entre método científico e técnica de pesquisa?

Resposta:
– **Método científico**: procedimentos lógicos gerais para produzir e validar conhecimento.
– **Técnica de pesquisa**: procedimento operacional específico (instrumentos, formulários).

Exercício 2

Em “sistemas que usam cache reduzem o tempo médio de resposta”, identifique VI e VD.

Resposta:
– **Variável independente**: uso de cache.
– **Variável dependente**: tempo médio de resposta.

Exercícios Complementares

Exercício 1

Qual a diferença entre método científico e técnica de pesquisa?

Resposta:
– **Método científico**: procedimentos lógicos gerais para produzir e validar conhecimento.
– **Técnica de pesquisa**: procedimento operacional específico (instrumentos, formulários).

Exercício 2

Em “sistemas que usam cache reduzem o tempo médio de resposta”, identifique VI e VD.

Resposta:
– **Variável independente**: uso de cache.
– **Variável dependente**: tempo médio de resposta.

Exercícios Complementares

Exercício 1

Qual a diferença entre método científico e técnica de pesquisa?

Resposta:
– **Método científico**: procedimentos lógicos gerais para produzir e validar conhecimento.
– **Técnica de pesquisa**: procedimento operacional específico (instrumentos, formulários).

Exercício 2

Em “sistemas que usam cache reduzem o tempo médio de resposta”, identifique VI e VD.

Resposta:
– **Variável independente**: uso de cache.
– **Variável dependente**: tempo médio de resposta.

Exercícios Complementares

Exercício 3

Proponha uma métrica objetiva e reprodutível para “manutenibilidade de código”.

Resposta: Ex.: complexidade ciclomática média ou índice de acoplamento entre módulos.

Exercício 4

Um estudo compara 3 devs usando a Ferramenta X e 3 usando a Y, sem aleatorização e com uma só tarefa. Que ameaça à validade é mais evidente?

Resposta: Validade interna (seleção) – sem aleatorização, não há como separar o efeito da ferramenta das diferenças individuais dos desenvolvedores.

Exercícios Complementares

Exercício 3

Proponha uma métrica objetiva e reprodutível para “manutenibilidade de código”.

Resposta: Ex.: complexidade ciclomática média ou índice de acoplamento entre módulos.

Exercício 4

Um estudo compara 3 devs usando a Ferramenta X e 3 usando a Y, sem aleatorização e com uma só tarefa. Que ameaça à validade é mais evidente?

Resposta: Validade interna (seleção) – sem aleatorização, não há como separar o efeito da ferramenta das diferenças individuais dos desenvolvedores.

Exercícios Complementares

Exercício 3

Proponha uma métrica objetiva e reprodutível para “manutenibilidade de código”.

Resposta: Ex.: complexidade ciclomática média ou índice de acoplamento entre módulos.

Exercício 4

Um estudo compara 3 devs usando a Ferramenta X e 3 usando a Y, sem aleatorização e com uma só tarefa. Que ameaça à validade é mais evidente?

Resposta: Validade interna (seleção) – sem aleatorização, não há como separar o efeito da ferramenta das diferenças individuais dos desenvolvedores.

Exercícios Complementares

Exercício 3

Proponha uma métrica objetiva e reprodutível para “manutenibilidade de código”.

Resposta: Ex.: complexidade ciclomática média ou índice de acoplamento entre módulos.

Exercício 4

Um estudo compara 3 devs usando a Ferramenta X e 3 usando a Y, sem aleatorização e com uma só tarefa. Que ameaça à validade é mais evidente?

Resposta: Validade interna (seleção) – sem aleatorização, não há como separar o efeito da ferramenta das diferenças individuais dos desenvolvedores.

Próxima Aula

Formulação de experimentos: comparação de sistemas e computação experimental.

Referências Bibliográficas

- BASILI, V. R.; SELBY, R. W.; HUTCHENS, D. H. Experimentation in Software Engineering. *IEEE Transactions on Software Engineering*, v. 12, n. 7, 1986.
- GIL, A. C. *Métodos e Técnicas de Pesquisa Social*. 6. ed. São Paulo: Atlas, 2008.
- LAKATOS, Eva Maria; MARCONI, Marina de Andrade. *Fundamentos de metodologia científica*. 5. ed. São Paulo: Atlas, 2003.
- POPPER, Karl R. *A lógica da pesquisa científica*. São Paulo: Cultrix, 2004.
- WAZLAWICK, R. S. *Metodologia de Pesquisa para Ciência da Computação*. 2. ed. Rio de Janeiro: Elsevier, 2014.
- WOHLIN, C.; RUNESON, P.; HÖST, M.; OHLSSON, M. C.; REGNELL, B.; WESSLÉN, A. *Experimentation in Software Engineering*. Springer, 2012.

PERGUNTAS?