

Métodos de Computação Experimental e Quantitativa

Aula 04: **Análise Exploratória e Estatística Descritiva**

Prof. Dr. Leonardo N. Ferreira e Prof. Dr. Wemerson D. Parreira

Conteúdo

1. Retomada: Tendência Central e Dispersão
2. Forma, Escala e Precisão da Estimativa
3. Detecção de Outliers e Regra do IQR
4. Visualização de Dados Experimentais
5. Aplicação Computacional em Python
6. Limitações e Exercícios Práticos

O que já vimos durante o curso

Nas últimas aulas aprendemos a **formular experimentos**:

- Pergunta de pesquisa e hipóteses (H_0/H_1);
- Definição de variáveis, aleatorização e blocagem.

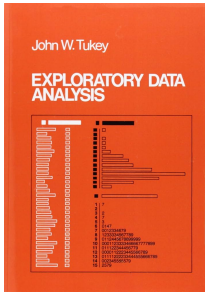
O que falta: Análise dos Dados

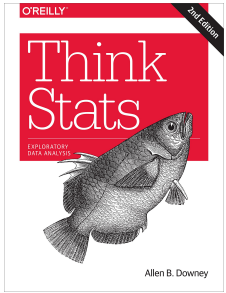
- O experimento produz **dados brutos** (listas de números);
- Antes de testar hipóteses, é preciso **descrever** e **visualizar**;
- Um resumo inadequado pode esconder o padrão real dos dados.

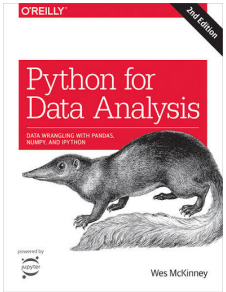
Análise Exploratória de Dados

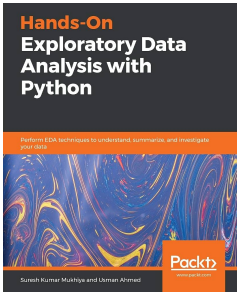
Livros de referência

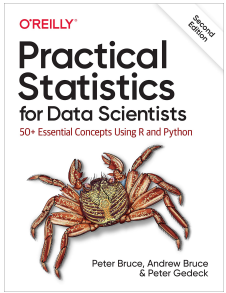
EDA: não é possível cobrir tudo neste curso!











REVISÃO RÁPIDA: TENDÊNCIA CENTRAL E DISPERSÃO

Revisão Rápida

Tendência e dispersão

- Vocês já conhecem estas medidas de outras disciplinas
- O importante aqui é: quando usar cada medida e não a fórmula.

Tendência central

Indica o **valor típico** ou representativo em torno do qual os dados se concentram.

Métricas comuns:

- **Média ($\bar{x}$)** – sensível a outliers;
- **Mediana** – robusta a assimetria/outliers;
- **Moda** – útil em dados multimodais.

Dispersão

Mede a **variabilidade** ou o espalhamento dos dados em torno do centro.

Métricas comuns:

- **Desvio padrão (s)** e Variância (s^2);
- **Amplitude** – sensível a extremos;
- **IQR** – robusto a outliers.

Revisão Rápida

Tendência e dispersão

- Vocês já conhecem estas medidas de outras disciplinas
- O importante aqui é: quando usar cada medida e não a fórmula.

Tendência central

Indica o **valor típico** ou representativo em torno do qual os dados se concentram.

Métricas comuns:

- **Média ($\bar{x}$)** – sensível a outliers;
- **Mediana** – robusta a assimetria/outliers;
- **Moda** – útil em dados multimodais.

Dispersão

Mede a **variabilidade** ou o espalhamento dos dados em torno do centro.

Métricas comuns:

- **Desvio padrão (s)** e Variância (s^2);
- **Amplitude** – sensível a extremos;
- **IQR** – robusto a outliers.

Revisão Rápida

Tendência e dispersão

- Vocês já conhecem estas medidas de outras disciplinas
- O importante aqui é: quando usar cada medida e não a fórmula.

Tendência central

Indica o **valor típico** ou representativo em torno do qual os dados se concentram.

Métricas comuns:

- **Média ($\bar{x}$)** – sensível a outliers;
- **Mediana** – robusta a assimetria/outliers;
- **Moda** – útil em dados multimodais.

Dispersão

Mede a **variabilidade** ou o espalhamento dos dados em torno do centro.

Métricas comuns:

- **Desvio padrão (s)** e Variância (s^2);
- **Amplitude** – sensível a extremos;
- **IQR** – robusto a outliers.

Problema Motivador Cenário

Cenário

Dois servidores (A e B) foram testados sob a mesma carga. Foram coletadas 30 medições de tempo de resposta (ms) de cada um. Um colega resume: “a média do Servidor A é 120 ms e a do B é 118 ms – são praticamente iguais”.

Perguntas

- Essa única frase é suficiente para decidir qual servidor é mais confiável em produção?
- O que a média **não** está contando?

Exemplo Resolvido

Impacto de outliers

Tempos de resposta (ms) – Servidor A

`115, 118, 119, 120, 121, 122, 118, 250`

- **Média** $\approx 135{,}4$ ms – puxada para cima por um valor (`250`);
- **Mediana** $= 119{,}5$ ms – reflete melhor o comportamento típico;
- **Desvio padrão** $s \approx 46{,}4$ ms (sem o outlier: $s \approx 2{,}3$ ms) – alto, refletindo o outlier;
- **IQR** $\approx 3{,}5$ ms ($Q_1 = 118$, $Q_3 = 121{,}5$ ms) – pequeno, mostrando que **a maioria** é estável.

Ponto-chave

A média sozinha (135,4 ms) daria uma impressão **errada** de que o servidor é lento – o problema é um evento pontual, não o comportamento típico.

Assimetria

Além de média e mediana

Coeficiente de assimetria (*skewness*)

Quantifica o quanto uma distribuição se afasta da simetria:

$$g_1 = \frac{\frac{1}{n}\sum_i (x_i - \bar{x})^3}{s^3}$$

$\bar{x}$ é a média e s é o desvio padrão amostral.

$g_1 \approx 0$: simétrica $\quad$ $g_1 > 0$: cauda à direita $\quad$ $g_1 < 0$: cauda à esquerda.

Por que isso importa agora

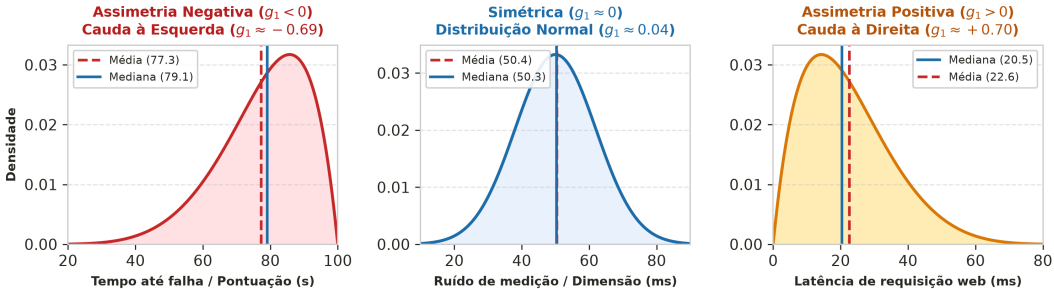
- Testes clássicos (ex.: Teste t) **assumem** normalidade (ou aproximação normal da média amostral pelo TCL);
- Forte assimetria indica o uso de testes **não paramétricos** (ex.: Wilcoxon).

Assimetria

Exemplos práticos de skewness

Comportamento de Média e Mediana

A cauda longa “arrasta” a média na sua direção, enquanto a mediana permanece robusta no centro.



Coeficiente de Variação

Escalas diferentes

Definição

$$CV = \frac{s}{\bar{x}} \times 100\%$$

Dispersão **relativa** à média – permite comparar a variabilidade de métricas com unidades diferentes (ex.: latência em ms vs. uso de memória em MB).

Exemplo

Latência: $\bar{x} = 500\,\text{ms}$, $s = 25\,\text{ms} \Rightarrow CV = 5\%$.

Uso de CPU: $\bar{x} = 40\%$, $s = 12\% \Rightarrow CV = 30\%$.

Mesmo com s numericamente maior na latência ($25 > 12$), a CPU é **proporcionalmente muito mais instável** ($30\% > 5\%$) – informação que o desvio padrão isolado não revela.

Identificação de Outliers

Regra do IQR

Regra de Tukey[1]

Um valor x é considerado outlier se:

$$x < Q_1 - 1{,}5 \times \text{IQR} \quad \text{ou} \quad x > Q_3 + 1{,}5 \times \text{IQR}$$

- É a mesma regra usada para desenhar os “bigodes” de um **boxplot**;
- Outlier **não significa erro de medição** – pode ser um evento real (ex.: pico de rede, garbage collection) que merece investigação, não descarte automático.

[1] John W. Tukey. *Exploratory Data Analysis.* Reading: Addison-Wesley, 1977.

Visualização de Dados

Por que visualizar?

Princípio

- Nenhuma medida-resumo isolada substitui **olhar para a forma dos dados**.
- Conjuntos com a mesma média, mediana e desvio padrão podem ter distribuições visualmente muito diferentes.

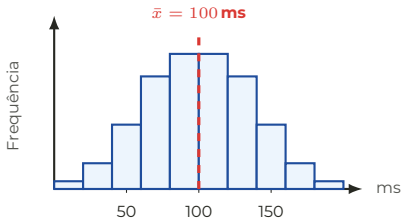
Três gráficos importantes em experimentos de Engenharia de Software:

- **Histograma**: forma da distribuição de uma variável;
- **Boxplot**: mediana, quartis e outliers – ótimo para comparar grupos (ex.: Servidor A vs. B);
- **Gráfico de dispersão**: relação entre duas variáveis.

Histograma

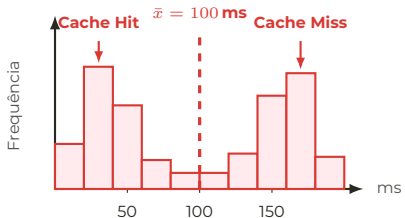
Diferenciando distribuições

Amostra A: Unimodal



Processo homogêneo (1 regime)

Amostra B: Bimodal



Mistura de populações (2 regimes)

Diferenciando amostras

- Médias idênticas ($\bar{x}_A = \bar{x}_B = 100$ ms) tratariam os servidores como equivalentes.
- O histograma revela que a Amostra B opera sob **dois regimes distintos**, diferenciando seu comportamento.

Boxplot

Descrição e visualização

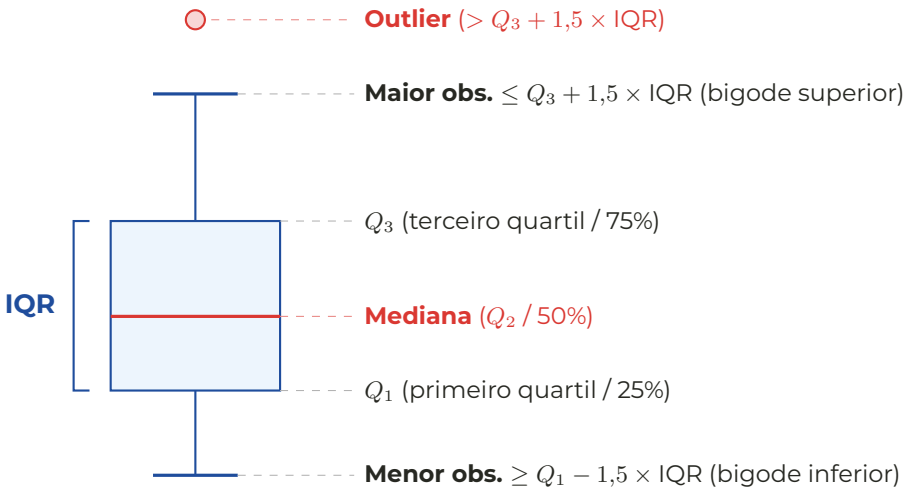
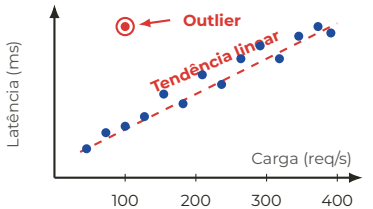


Gráfico de Dispersão

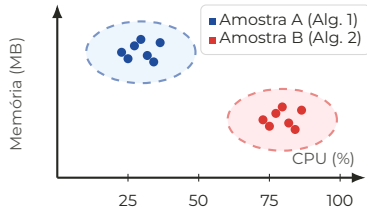
Relações e agrupamentos

1. Encontrando Relações



Correlação e detecção de anomalias

2. Diferenciando Amostras



Separação em clusters 2D

Relações e Agrupamentos

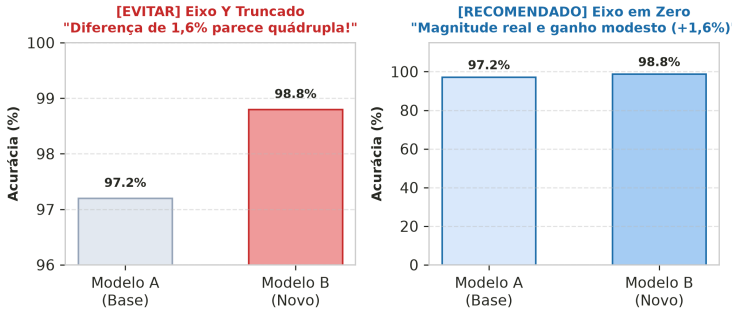
O gráfico de dispersão avalia a **natureza de dependências** entre variáveis e permite **diferenciar amostras (clusters)** que seriam indistinguíveis se projetadas em um só eixo.

Gráficos Científicos

Princípio 1: Eixos em zero

Princípio 1

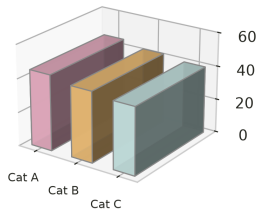
Eixos devem começar em zero quando a comparação de magnitude importa. Truncar a escala vertical exagera pequenas variações, induzindo o leitor a superestimar diferenças modestas.



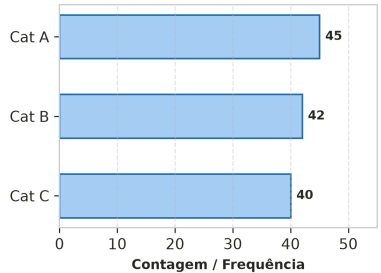
Princípio 2

Evite gráficos tridimensionais e adornos decorativos (*chartjunk*). A perspectiva distorce ângulos e áreas, enquanto gráficos 2D diretos permitem julgamento visual imediato.

[EVITAR] 3D e Chartjunk
"Perspectiva e sombras distorcem a leitura"

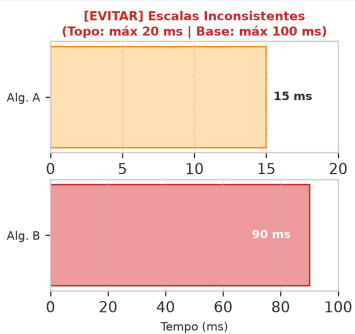


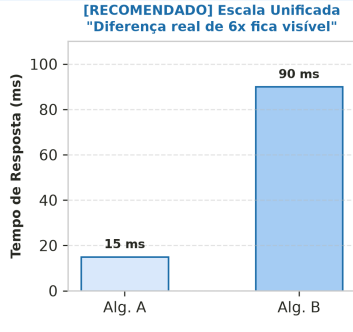
[RECOMENDADO] 2D Direto e Limpo
"Alinhamento horizontal preciso e sem ruído"



Princípio 3

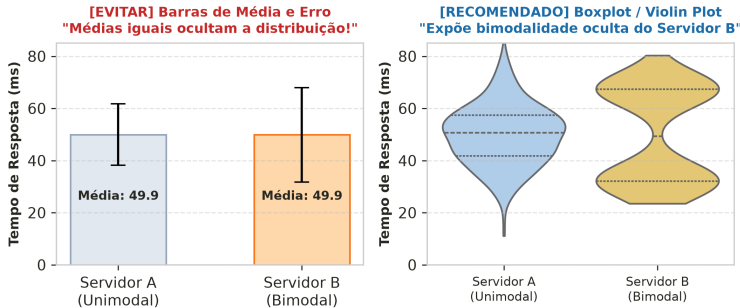
Escalas e unidades devem ser idênticas e visíveis entre gráficos comparados. Limites de eixos arbitrários induzem o leitor a enxergar equivalência onde existe disparidade real.





Princípio 4

Prefira boxplot ou violin plot a barras de média ± erro quando a distribuição pode ser assimétrica ou multimodal. Barras com médias idênticas ocultam a real dispersão dos dados.



APLICAÇÃO COMPUTACIONAL

Aplicação Problema motivador

Problema (retomado do início da aula)

Um colega concluiu que os servidores A e B são “praticamente iguais” porque as médias de tempo de resposta (120 ms e 118 ms) são próximas.

O que vamos implementar a seguir, para dados simulados:

1. **Parte 1**: calcular, para cada servidor, as medidas de tendência central, dispersão e IQR vistas nesta aula;
2. **Parte 2**: construir boxplot e histograma comparando os dois servidores.

Pergunta que o código deve responder

As medidas e os gráficos confirmam a conclusão do colega, ou revelam algo que a média sozinha escondia?

Aplicação Problema motivador

Problema (retomado do início da aula)

Um colega concluiu que os servidores A e B são “praticamente iguais” porque as médias de tempo de resposta (120 ms e 118 ms) são próximas.

O que vamos implementar a seguir, para dados simulados:

1. **Parte 1**: calcular, para cada servidor, as medidas de tendência central, dispersão e IQR vistas nesta aula;
2. **Parte 2**: construir boxplot e histograma comparando os dois servidores.

Pergunta que o código deve responder

As medidas e os gráficos confirmam a conclusão do colega, ou revelam algo que a média sozinha escondia?

Aplicação Problema motivador

Problema (retomado do início da aula)

Um colega concluiu que os servidores A e B são “praticamente iguais” porque as médias de tempo de resposta (120 ms e 118 ms) são próximas.

O que vamos implementar a seguir, para dados simulados:

1. **Parte 1**: calcular, para cada servidor, as medidas de tendência central, dispersão e IQR vistas nesta aula;
2. **Parte 2**: construir boxplot e histograma comparando os dois servidores.

Pergunta que o código deve responder

As medidas e os gráficos confirmam a conclusão do colega, ou revelam algo que a média sozinha escondia?

Aplicação Estatísticas descritivas

```python
import numpy as np
import pandas as pd

rng = np.random.default_rng(7)

# tempos de resposta (ms) — servidor B com cauda longa moderada (Gamma, shape=4)
servidor_a = np.concatenate([rng.normal(120, 4, 29), [250]])
servidor_b = rng.gamma(shape=4, scale=30, size=30)

df = pd.DataFrame({"A": servidor_a, "B": servidor_b})

resumo = df.describe(percentiles=[0.25, 0.5, 0.75])
print(resumo.round(1))

iqr = df.quantile(0.75) - df.quantile(0.25)
print("IQR:")
print(iqr.round(1))
```

Aplicação Visualização

```
              A      B
count    30.0   30.0
mean    122.7  109.9
std      24.3   53.7
min     109.9   30.7
25%     116.3   71.7
50%     119.0  101.2
75%     120.6  139.2
max     250.0  269.6
IQR:
A     4.3
B    67.5
dtype: float64
```

Aplicação Visualização

```python
import matplotlib.pyplot as plt

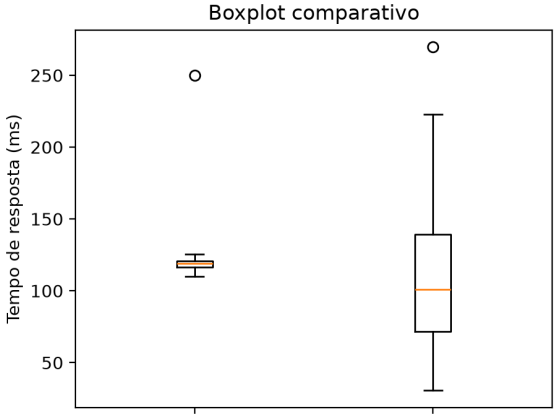
fig, ax = plt.subplots(1, 2, figsize=(9, 4))

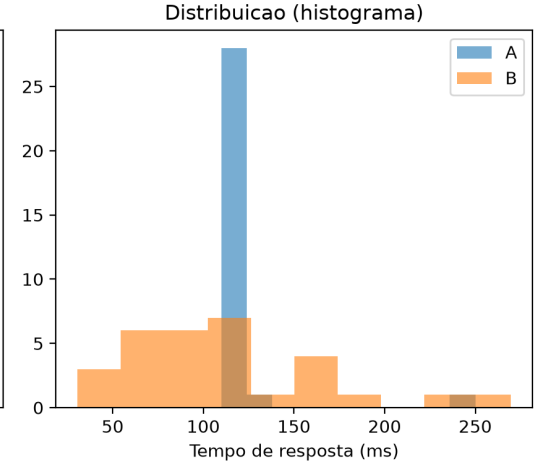
ax[0].boxplot([df["A"], df["B"]],
              tick_labels=["Servidor A", "Servidor B"])
ax[0].set_ylabel("Tempo de resposta (ms)")
ax[0].set_title("Boxplot comparativo")

ax[1].hist(df["A"], bins=10, alpha=0.6, label="A")
ax[1].hist(df["B"], bins=10, alpha=0.6, label="B")
ax[1].set_xlabel("Tempo de resposta (ms)")
ax[1].legend()
ax[1].set_title("Distribuicao (histograma)")

plt.tight_layout()
plt.savefig("comparacao_servidores.png", dpi=150)
```

Aplicação Visualização





Aplicação Interpretação dos resultados

- O `describe()` mostra que médias podem ficar próximas mesmo com formas de distribuição muito diferentes;
- O **boxplot** revela o outlier do Servidor A e a possível assimetria (cauda longa) do Servidor B – informação que a média sozinha esconde;
- O **histograma** mostra a forma completa: unimodal e simétrico vs. assimétrico à direita;

Conclusão

Comparar servidores exige olhar para **mediana + dispersão + forma**, não apenas para a média.

Limitações Estatística descritiva

- **Não testa hipóteses**:
  - Apenas organiza e sintetiza os dados observados;
  - Decidir se o efeito é real ou ruído amostral exige inferência estatística.

- **Resumos numéricos perdem informação**:
  - Métricas isoladas omitem assimetrias e a forma real dos dados;
  - Regra prática: sempre **visualizar antes de resumir**.

- **Sensibilidade de parâmetros visuais**:
  - O número de *bins* no histograma pode distorcer a distribuição;
  - Recomenda-se testar diferentes configurações.

Limitações Estatística descritiva

- **Não testa hipóteses**:
  - Apenas organiza e sintetiza os dados observados;
  - Decidir se o efeito é real ou ruído amostral exige inferência estatística.

- **Resumos numéricos perdem informação**:
  - Métricas isoladas omitem assimetrias e a forma real dos dados;
  - Regra prática: sempre **visualizar antes de resumir**.

- **Sensibilidade de parâmetros visuais**:
  - O número de *bins* no histograma pode distorcer a distribuição;
  - Recomenda-se testar diferentes configurações.

Limitações Estatística descritiva

- **Não testa hipóteses**:
  - Apenas organiza e sintetiza os dados observados;
  - Decidir se o efeito é real ou ruído amostral exige inferência estatística.

- **Resumos numéricos perdem informação**:
  - Métricas isoladas omitem assimetrias e a forma real dos dados;
  - Regra prática: sempre **visualizar antes de resumir**.

- **Sensibilidade de parâmetros visuais**:
  - O número de *bins* no histograma pode distorcer a distribuição;
  - Recomenda-se testar diferentes configurações.

Exercício 1 Pipeline de CI

Dados

Tempos de build (s) de um pipeline de CI (*Continuous Integration*) em 10 execuções:

```
42, 45, 44, 43, 46, 44, 45, 90, 43, 44
```

Em duplas:

1. Calculem média, mediana e desvio padrão;
2. Apliquem a regra do IQR e identifiquem outliers;
3. Esbocem, à mão, o boxplot desses dados;
4. Expliquem, em uma frase, por que a média seria uma escolha ruim para reportar ao time.

Exercício 1 Respostas: Questões 1 e 2

1. **Média, Mediana e Desvio Padrão**:
   - **Média**: $\bar{x} = \frac{486}{10} = \mathbf{48{,}6}\,\text{s}$
   - **Mediana**: Md $= \frac{44+44}{2} = \mathbf{44}\,\text{s}$
   - **Desvio Padrão**: $s \approx \mathbf{14{,}6}\,\text{s}$
   - *Sem o outlier (90 s):* $\bar{x} = 44{,}0\,\text{s}$ e $s = 1{,}2\,\text{s}$.

2. **Regra do IQR e Identificação de Outliers**:
   - Quartis: $Q_1 = 43\,\text{s}$ e $Q_3 = 45\,\text{s} \implies \text{IQR} = 45 - 43 = \mathbf{2}\,\text{s}$
   - Limite superior: $Q_3 + 1{,}5 \times \text{IQR} = 45 + 1{,}5(2) = \mathbf{48}\,\text{s}$
   - Limite inferior: $Q_1 - 1{,}5 \times \text{IQR} = 43 - 1{,}5(2) = \mathbf{40}\,\text{s}$
   - Como $90 > 48\,\text{s}$, o valor **90 s é formalmente classificado como outlier**.

Exercício 1 Respostas: Questões 1 e 2

1. **Média, Mediana e Desvio Padrão**:
   - **Média**: $\bar{x} = \frac{486}{10} = \mathbf{48{,}6}$ s
   - **Mediana**: Md $= \frac{44+44}{2} = \mathbf{44}$ s
   - **Desvio Padrão**: $s \approx \mathbf{14{,}6}$ s
   - *Sem o outlier (90 s):* $\bar{x} = 44{,}0$ s e $s = 1{,}2$ s.

2. **Regra do IQR e Identificação de Outliers**:
   - Quartis: $Q_1 = 43$ s e $Q_3 = 45$ s $\implies$ IQR $= 45 - 43 = \mathbf{2}$ s
   - Limite superior: $Q_3 + 1{,}5 \times \text{IQR} = 45 + 1{,}5(2) = \mathbf{48}$ s
   - Limite inferior: $Q_1 - 1{,}5 \times \text{IQR} = 43 - 1{,}5(2) = \mathbf{40}$ s
   - Como $90 > 48$ s, o valor **90 s é formalmente classificado como outlier**.

Exercício 1 Respostas: Questões 3 e 4

3. **Esboço do Boxplot**:
   - **Haste inferior**: valor mínimo não-outlier em $42\,\text{s}$;
   - **Caixa (Q_1 a Q_3)**: de $43\,\text{s}$ a $45\,\text{s}$, com a **mediana** marcada em $44\,\text{s}$;
   - **Haste superior**: valor máximo não-outlier em $46\,\text{s}$;
   - **Outlier**: ponto isolado à direita em **90 s**.

4. **Por que a média é uma escolha ruim para reportar ao time**:
   - A média ($48{,}6\,\text{s}$) é inflacionada por **um único evento atípico**
   - passando a falsa impressão de que o pipeline piorou de forma geral.
   - Já a **mediana (44 s)** comunica com fidelidade o comportamento típico do sistema.

Exercício 1 Respostas: Questões 3 e 4

3. **Esboço do Boxplot**:
   - **Haste inferior**: valor mínimo não-outlier em $42\,\text{s}$;
   - **Caixa (Q_1 a Q_3)**: de $43\,\text{s}$ a $45\,\text{s}$, com a **mediana** marcada em $44\,\text{s}$;
   - **Haste superior**: valor máximo não-outlier em $46\,\text{s}$;
   - **Outlier**: ponto isolado à direita em **90 s**.

4. **Por que a média é uma escolha ruim para reportar ao time**:
   - A média ($48{,}6\,\text{s}$) é inflacionada por **um único evento atípico**
   - passando a falsa impressão de que o pipeline piorou de forma geral.
   - Já a **mediana (44 s)** comunica com fidelidade o comportamento típico do sistema.

Exercício 2 Base real do Kaggle

Base de dados: Software Defect Prediction

Métricas estáticas de código (ex.: linhas de código, complexidade) associadas a um rótulo indicando se o módulo apresentou defeito:

`https://www.kaggle.com/datasets/semustafacevik/software-defect-prediction`

Passo a passo:

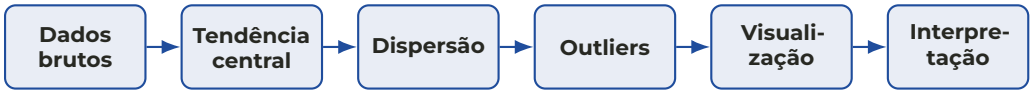
1. Criar conta gratuita no Kaggle e baixar o CSV da base acima;
2. Carregar os dados em Python (`pandas`) e explorar as colunas com `df.info()` / `df.head()`;
3. Escolher **uma métrica de código** (ex.: linhas de código) disponível na base;

Exercício 2 Passo a passo da análise

Para a métrica escolhida, comparando módulos **com** e **sem** defeito:

1. Calcule média, mediana, desvio padrão e IQR em cada grupo;
2. Aplique a regra do IQR e identifique outliers;
3. Construa um **boxplot** comparando os dois grupos;
4. Construa um **histograma** da métrica;
5. Calcule a assimetria;
6. Obtenha o coeficiente de variação.

Resumo da aula

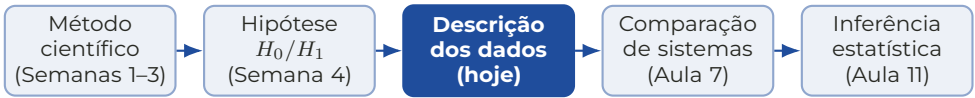


Observação

Antes de perguntar “a diferença é estatisticamente significativa?”, é preciso saber **descrever honestamente** os dados – e isso exige mais de uma medida e, quase sempre, um gráfico.

Visão Geral

Onde estamos na disciplina



O elo que a estatística descritiva fornece

- **Forma** (simétrica vs. assimétrica) → antecipa se o teste será paramétrico ou não paramétrico;
- **Dispersão** (desvio padrão, IQR) → insumo para intervalos de confiança;
- **Visualização** → valida premissas antes de qualquer teste de hipótese.

Referências Bibliográficas I


Cleveland, William S. *The Elements of Graphing Data*. Rev. ed. Summit: Hobart Press, 1994.


Montgomery, Douglas C. e George C. Runger. *Applied Statistics and Probability for Engineers*. 7ª ed. Hoboken: Wiley, 2018.


Tukey, John W. *Exploratory Data Analysis*. Reading: Addison-Wesley, 1977.


Wohlin, Claes et al. *Experimentation in Software Engineering*. Springer, 2012.